

ECFD — Test 0 Report: The Brain on Typed Sentences

Egyptian Conversational Fraud Defense · 6th of October University · Generated 04 October 2026 · Prompt version 937a1eeb7f

Test 0: PASS — the default brain (GPT-OSS-120B via Groq) labelled **18 of 20** sentences exactly right (pass line: 15) and **0** invented quotes survived (pass line: 0). Median response time **1.1 s**.

1. What was tested

- **Goal:** check that the NLP "brain" (pipeline stage 6) labels social-engineering tactics in Egyptian Arabic correctly *before* adding speech recognition and live calls.
- **Input:** 20 typed caller sentences (DEV set) with hand-written expected labels, including traps: warnings that mention OTP, genuine IT and work requests, an OTP request without the word «كود», and a short reply that only makes sense with the two previous turns.
- **Brain:** one LLM call per sentence, temperature 0, forced tool call returning `tactics[label, confidence low|medium|high, quote]` and `needs_more_context`. 11 labels: `identity_claim`, `authority`, `urgency`, `fear_threat`, `secrecy`, `verification_bypass`, `otp_request`, `credential_request`, `payment_request`, `remote_access_request`, `sensitive_action_request`.
- **Safeguard:** every label must quote words that really appear in the sentence (after Arabic normalisation); otherwise it is dropped.
- **Correct** means the set of accepted labels equals the expected set exactly (confidence ignored).
- **Pass lines (pre-agreed):** at least 15 of 20 exactly correct; zero invalid quotes kept.

2. Results by model

Model	Exactly correct	Invalid quotes kept	Labels dropped by safeguard	Median time	Slowest	Result
GPT-OSS-120B via Groq Default brain · free · ~1,000 requests/day	18/20	0	1	1.1 s	11.6 s	PASS
Gemini 3.5 Flash Free tier · 20 requests/day	16/18 (2 not run)	0	0	2.9 s	33.4 s	INCOMPLETE

Both models used the identical prompt and safeguards. Gemini stopped after 18 sentences because its free tier allows only 20 requests per day per model; that limit also rules it out for live calls (one 3-minute call ≈ 15–30 requests). Groq was therefore made the default brain.

3. Sentence by sentence

#	Caller sentence	Expected	GPT-OSS-120B via Groq	Gemini 3.5 Flash
T01	أنا أحمد من الدعم الفني بتاع البنك Claim only. Real IT says this too.	identity_claim	PASS identity_claim high «أنا احمد من الدعم الفني»	PASS identity_claim high «أنا احمد من الدعم الفني بتاع البنك»
T02	أهلا يا فندم، معاك منى من خدمة العملاء بخصوص الشكوى اللي حضرتك قدمتها امبارح Legitimate-sounding claim, still a claim.	identity_claim	PASS identity_claim high «معاك منى من خدمة العملاء»	PASS identity_claim high «معاك منى من خدمة العملاء»
T03	ابعتلي الكود اللي جالك في الرسالة دلوقتي Direct OTP request + 'now'.	otp_request, urgency	PASS otp_request high «ابعتلي الكود» urgency high «دلوقتي»	PASS otp_request high «ابعتلي الكود اللي جالك في الرسالة» urgency high «دلوقتي»
T04	عمرك ما تدي حد ال OTP بتاعك حتى لو قال إنه من البنك Warning, not a request (key rule).	no label	PASS no label	PASS no label
T05	لو ما أكدتش العملية في خلال عشر دقائق الحساب هيتقفل نهائي Deadline + threat of closure.	urgency, fear_threat	PASS urgency high «في خلال عشر دقائق» fear_threat high «الحساب هيتقفل نهائي»	MISS urgency high «في خلال عشر دقائق» fear_threat high «الحساب هيتقفل نهائي» sensitive_action_request medium «أكدتش العملية»
T06	قولي الباسورد بتاع حسابك عشان أعملك reset Password request, code-switched.	credential_request	PASS credential_request high «قولي الباسورد»	PASS credential_request high «قولي الباسورد بتاع حسابك»

#	Caller sentence	Expected	GPT-OSS-120B via Groq	Gemini 3.5 Flash
T07	محتاج رقم الكارت وال CVV اللي ورا عشان أوقف العملية المشبوهة Card number + CVV.	credential_request	PASS credential_request high «رقم الكارت وال cvv»	MISS credential_request high «محتاج رقم الكارت وال اللي ورا» fear_threat medium «عشان اوقف العملية المشبوهة»
T08	حول المبلغ على انستاباي على الرقم ده عشان نأمن فلوسك Transfer request.	payment_request	PASS payment_request high «حول المبلغ علي انستاباي علي الرقم ده»	PASS payment_request high «حول المبلغ علي انستاباي علي الرقم ده»
T09	نزل AnyDesk وابعتلي الرقم اللي هيظهرلك Remote-access install.	remote_access_request	MISS remote_access_request high «nزل anydesk» credential_request high «ابعتلي الرقم اللي هيظهرلك»	PASS remote_access_request high «نزل anydesk وابعتلي الرقم اللي هيظهرلك»
T10	الموضوع ده سري، ما تقولش لحد في الفرع Hide the call.	secrecy	PASS secrecy high «ما تقولش لحد»	PASS secrecy high «الموضوع ده سري، ما تقولش لحد في الفرع»
T11	مش لازم تروح الفرع، أنا هخلصك كل حاجة من هنا على التليفون Skip in-person verification.	verification_bypass	PASS verification_bypass high «مش لازم تروح الفرع»	PASS verification_bypass high «مش لازم تروح الفرع، أنا هخلصك كل حاجة من هنا علي التليفون»
T12	دي تعليمات مباشرة من مدير الإدارة ولازم تتنفذ Invokes orders/rank.	authority	PASS authority high «دي تعليمات مباشرة من مدير الادارة»	PASS authority high «دي تعليمات مباشرة من مدير الادارة ولازم تتنفذ»
T13	هيوصلك لينك، افتحه ووافق على الطلب اللي هيظهرلك Click link + approve prompt.	sensitive_action_request	MISS × sensitive_action_request dropped: quote not found in the turn «افتح ووافق علي الطلب»	PASS sensitive_action_request high «هيوصلك لينك، افتحه ووافق علي الطلب اللي هيظهرلك»

#	Caller sentence	Expected	GPT-OSS-120B via Groq	Gemini 3.5 Flash
T14	تمام يا فندم، الاجتماع الساعة خمسة في الدور التالت Benign.	no label	PASS no label	PASS no label
T15	ممكن تبعتلي التقرير بتاع الشهر ده على الإيميل؟ Ordinary work request (rule 2).	no label	PASS no label	PASS no label
T16	البنك عمره ما هيطلب منك الرقم السري على التليفون Policy statement, not a request.	no label	PASS no label	PASS no label
T17	اقرالي الأرقام اللي جاتلك على الموبايل حالا OTP request without the word 'code'.	otp_request, urgency	PASS otp_request high «اقرالي الارقام اللي جاتلك علي الموبايل» urgency high «حالا»	PASS otp_request high «اقرالي الارقام اللي جاتلك علي الموبايل» urgency high «حالا»
T18	لو مش هتتعاون معايا هنضطر نبغ عنك وتتعرض للمساءلة القانونية Legal threat.	fear_threat	PASS fear_threat high «هنضطر نبغ عنك وتتعرض للمساءلة القانونية»	PASS fear_threat high «هنضطر نبغ عنك وتتعرض للمساءلة القانونية»
T19	ابعتهولي بسرعة context (previous turns): أنا من الدعم الفني هيوصلك كود تأكيد على الموبايل دلوقتي 'it' = the code; needs the context turns.	otp_request, urgency	PASS otp_request high «ابعتهولي» urgency high «سرعة»	— not run (daily quota)
T20	ال system عندنا واقع، ممكن تعمل restart للجهاز وتجرب تاني؟ Normal IT help, not a sensitive action.	no label	PASS no label	— not run (daily quota)

4. The misses, explained

- **T09 (GPT-OSS):** correct `remote_access_request`, plus an extra `credential_request` for «ابعتلي الرقم» «اللي هيظهرلك». That number is the AnyDesk ID, which grants access — the extra label is arguable. *Needs a team decision on the expected answer.*
- **T13 (GPT-OSS):** the model chose the right label but quoted «افتح» instead of the real «افتحه», so the safeguard dropped it. The safety net worked as designed; it cost one label. Not changed yet (one change at a time); watch for this in later tests.
- **T05 (Gemini):** extra `sensitive_action_request` for «أكدتش العملية» — the caller does indirectly push to confirm a transaction. Arguable.
- **T07 (Gemini):** extra `fear_threat` (medium) for «أوقف العملية المشبوهة» — mild fear framing. Arguable.

All four misses are **extra** labels or a dropped label; no model missed a fraud request, and no model labelled a warning («OTP عمرك ما تدي حد ال») or ordinary work request as a tactic.

5. Limitations — read before quoting these numbers

- **Expected labels were drafted by an AI assistant** (Claude, 3 October 2026) and have not yet been reviewed by a native Egyptian-Arabic speaker. T05, T07 and T09 in particular need a team decision.
- **Typed, clean text.** Real calls add speech-recognition errors (expected word error rate 30–45%). Test 1 and Test 2 measure that.
- **DEV set only, 20 sentences.** Prompt tuning on these is allowed; these numbers must not be reported as final accuracy. Final results come from the held-out test set.
- **Latency is per sentence over the internet** on free tiers; occasional slow outliers come from provider overload and retries. Test 2 measures end-to-end delay.

6. Next steps

- Team review of the expected labels (T05, T07, T09); fix the expected answers, not the prompt, if the model was right.
- Test 1 — speech: 10–15 phone-quality clips through Speechmatics; keyword recall on protected words $\geq 70\%$.
- Keep Claude Sonnet 5.5 as the target brain when credit is available; re-run this exact test for a fair comparison (one setting: `LLM_PROVIDER`).

Reproduce: `python ml/brain/run_test0.py` (re-uses saved answers) · regenerate this report: `python ml/brain/make_test0_report.py`